

Отчет к ДЗ-4 по NLP

Гришина

Часть 1. LoRA

К этой части относятся файлы `utils.py` и `lora.py`.

Сначала я взяла модель GPT2 для обучения и соответствующий ей токенайзер, внедрила lora в эту модель. Были сложности с доступом к слоям и с тем, как их сопоставить. Долго пыталась понять, почему выходы модели имеют неправильную размерность, и размерность логитов меньше числа токенов. Оказалось, что брала обезглавленную модель gpt2. Изменила модель на pythia-1.4b, адаптировала под нее внедрение LoRA и обучение, из-за проблем с памятью (не моей, а ресурсной), пришлось снизить и batch size, и максимальную длину последовательности, что впоследствии скажется на качестве модели. Также немного пришлось поподбирать lr, чтобы loss не скакал, а более стабильно уменьшался.

У базовой модели 1.4 миллиарда параметров, в LoRA части для нее - 3.3 миллиона, то есть при обучении только адаптора обучаемых параметров будет в ~400 раз меньше, чем если дообучать полную исходную модель, примерно во столько же раз должно ускоряться и обучение. Несколько дольше может быть инференс, потому что параметры были добавлены, но блоки LoRA параллельны основным линейным слоям, и при параллелизации вычислений в этих местах будет увеличенное число операций, но время вычислений не будет сильно меняться.

Буквально за 10 итераций loss уменьшился до ~1.8 и до конца эпохи кружил вокруг этого значения, так что я решила ее ставить модель обучаться на вторую эпоху. Логично: у блоков лоры не так много параметров, чтобы это имело смысл. Эпоха отбежала за ~9 минут,

Часть 2. Supervised fine-tuning.

К этой части относится файл `sft.py`.

В прошлой части я ставила задачу предсказания моделью следующего токена, в этой же части надо предсказывать полноценный ответ, то есть текст из множества токенов. Из-за этого и другого представления датасета было необходимо модифицировать функции обучения модели и реализовать последовательное предсказание нескольких токенов для генерации текста.

Код для дз я запускала в колабе и каггле, и приходилось много мучиться с оптимальным использованием памяти, удалять уже ненужные данные и модели, чистить память во время исполнения кода, сохранять чекпоинты моделей и использовать их... все это заняло очень много времени и было непростой задачей.